MVP de Engenharia de Dados

Prof. Victor Almeida

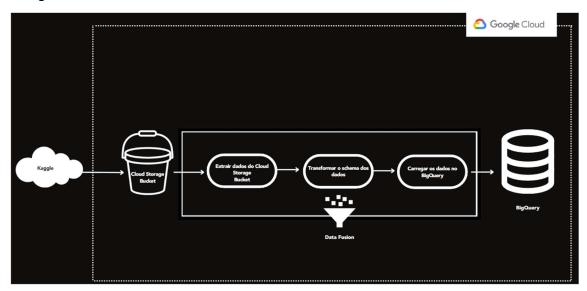
Aluna: Carmem Maria Marinho de Souza Vasconcelos

Introdução

Este documento apresenta parte do MVP de Engenharia de Dados, referente a Sprint 3 do curso de Pós-Graduação em Ciências de Dados e Analytics, da PUC-Rio.

O MVP consiste em construir um pipeline de dados utilizando tecnologias na nuvem. O pipeline irá envolver a busca, coleta, modelagem, carga e análise dos dados.

Nesta Parte 1, serão expostos a busca, coleta, modelagem e carga, conforme imagem abaixo.



A Análise (qualidade dos dados e solução do problema) e Autoavaliação estão na Parte 2 do MVP, apresentado no notebook do Colab, que pode ser acessado no link abaixo:

https://github.com/CarmemMarinho/poscienciasdedados/blob/main/MVP_Srint3 _EngenhariaDeDados_Parte2.ipynb.

1. Objetivo

Uma das etapas mais desafiadoras na jornada do empreendedorismo reside no planejamento inicial. Estabelecer o produto/serviço a ser oferecido e identificar o público-alvo demanda uma extensa pesquisa e uma atenção minuciosa, uma vez que esses são fatores críticos para determinar o êxito da empresa.

Todos os dias, muitas pessoas procuram o Sebrae buscando apoio na fase de planejamento do negócio. Há pouco tempo, durante meu trabalho no Sebrae, um dos clientes comentou que gostaria de trabalhar com gênero masculino e perguntou qual seria o melhor produto/serviço para empreender.

A partir desse questionamento senti a falta de um trabalho no Sebrae focado na análise do comportamento do consumidor, que pudesse responder à pergunta do cliente e oferecer suporte na tomada de decisão durante o planejamento do empreendimento. Então, defini como objetivo desse MPV analisar o perfil dos consumidores masculinos e encontrar o segmento ideal para investir na abertura de uma empresa. Para ajudar nessa análise, procurou-se responder as seguintes perguntas:

- 1. Como a idade do cliente influencia no seu comportamento de compra?
- 2. Existem padrões discerníveis nas vendas em diferentes períodos de tempo?
- 3. Quais são as relações entre idade e gastos dos clientes?

Especificamente, vamos buscar responder também as questões abaixo:

- Qual a faixa etária dos clientes por categoria do produto?
- Qual a idade dos clientes que compram mais em quantidade por categoria?
- Qual a idade dos clientes que compram mais em valor por categoria?
- Qual o mês com maior faturamento por categoria?
- Qual o mês com maior quantidade de produtos vendidos por categoria?
- Quais meses do ano apresentaram queda no volume de vendas (quantidade)?
- Quais meses do ano apresentaram queda no volume de vendas (faturamento)?
- Qual a categoria de produto mais vendido em quantidade no período total?
- Qual a categoria de produto com maior faturamento no período total?

Busca e Coleta de Dados

Os dados utilizados neste projeto estão presentes no Dataset Retails, obtidos no Kaggle (www.kaggle.com), de domínio público. Ele apresenta informações de varejo e as interações com os clientes, o que possibilita revelar tendências de varejo, por meio da análise dos padrões de vendas e perfis de clientes.

Embora seja um dataset com dados de um cenário fictício, ele reflete cenários de varejo do mundo real, permitindo praticar a análise em um contexto familiar.

Inclui os seguintes atributos: ID da transação, data, ID do cliente, sexo, idade, categoria do produto, quantidade, preço por unidade e valor total. Esses atributos permitem uma exploração de tendências de vendas, influências demográficas e comportamentos de compra.

Para mais detalhes sobre este dataset, consulte: Retails Sales: https://www.kaggle.com/datasets/mohammadtalib786/retail-sales-dataset

O dataset possui 1000 linhas e 9 atributos.

Informações dos Atributos:

Transaction_ID: Um identificador exclusivo para cada transação

Date: Data em que a transação ocorreu

Customer ID: Identificador exclusivo para cada cliente

Gender: O gênero do cliente

Age: Idade do cliente

Product_Category: Categoria do produto adquirido

Quantity: Quantidade de unidades do produto adquiridas

Price_per_Unit: Preço de uma unidade do produto

Total Amount: Valor monetário total da transação

3. Modelagem de Dados

Os dados estão dispostos em um modelo flat, numa única tabela em um arquivo com formato csv.

<u>Catálogo de Dados</u> - Foi realizado utilizando os recursos do BigQuery. Durante a etapa de transformação, conforme apresentado mais abaixo, foram realizados filtro e exclusões de atributos. Dessa forma o catálogo de dados foi elaborado com as informações a seguir:

Date: Data em que a transação ocorreu.

Customer ID: ID do cliente. Identificador exclusivo para cada cliente.

Age: Idade do cliente. Os valores são entre 18 e 64 anos.

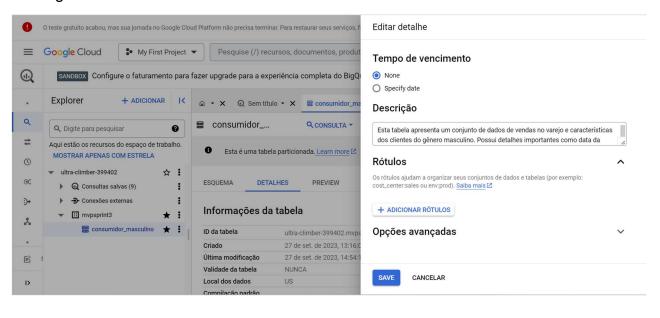
Product_Category: Categoria do produto adquirido. São os segmentos aos quais os produtos pertencem: Beauty, Clothing e Electronics.

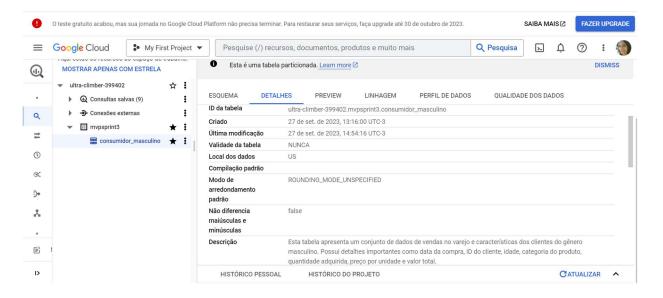
Quantity: Quantidade de unidades do produto adquiridas. São valores positivos e diferentes de zero. Os valores são entre 1 e 4 unidades.

Price_per_Unit: Preço unitário do produto. São valores positivos e diferentes de zero.

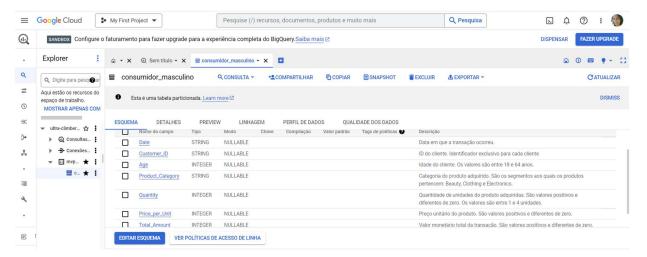
Total_Amount: Valor monetário total da transação. São valores positivos e diferentes de zero.

A seguir, a imagem apresenta a inserção da descrição da tabela, para compor o catálogo de dados -





Abaixo, a imagem apresenta a inserção da descrição dos atributos, para compor o catálogo de dados -



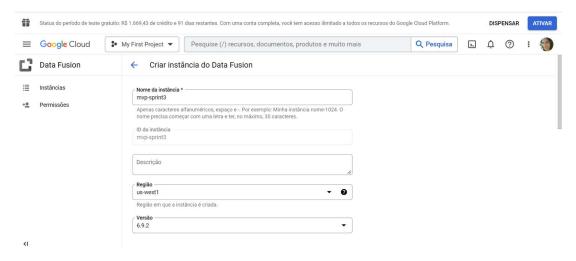
<u>Linhagem dos Dados</u> - Os dados foram obtidos no Kaggle (<u>www.kaggle.com</u>), realizando download do arquivo com formato csv, para o meu computador.

4. Carga

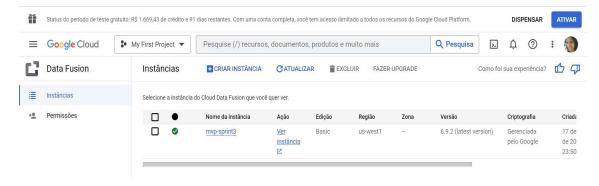
Para execução do trabalho foram utilizadas as ferramentas da Plataforma Google Cloud (GCP). Na extração, transformação e carga para o banco de dados, utilizei a ferramenta de ETL Data Fusion e para o Data Lake utilizei a plataforma BigQuery.

Iniciei criando a instância <u>mvp-sprint3</u> no Data Fusion, conforme imagens abaixo.

Configurando a instância -

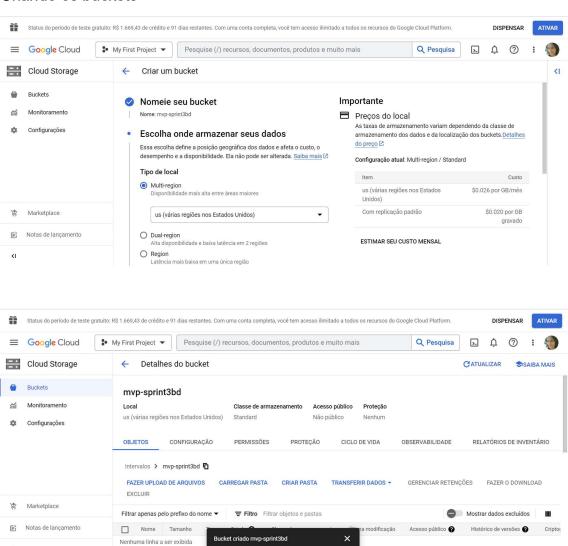


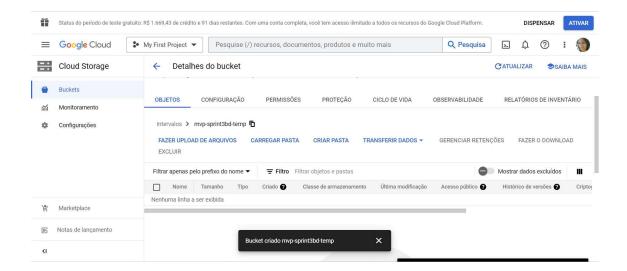
Instância criada -



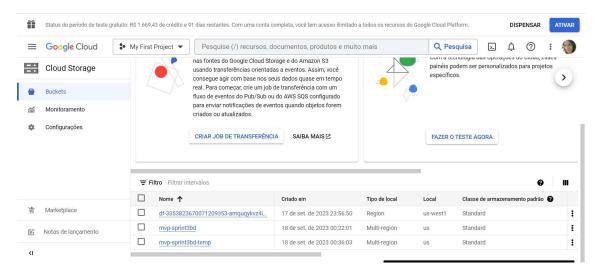
Em seguida, para inserir os dados coletados na Plataforma Google Cloud, no serviço Cloud Storage, criei o bucket <u>mvp-sprint3bd</u>, para onde fiz o upload do dataset coletado, e o bucket temporário mvp-sprint3bd-temp.

Criando os buckets -

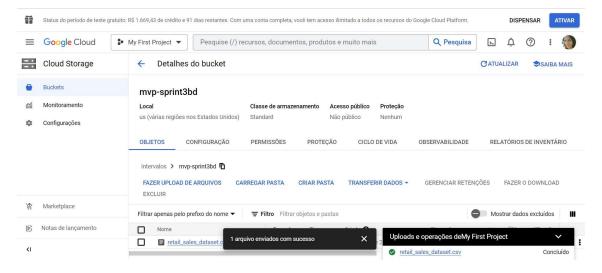




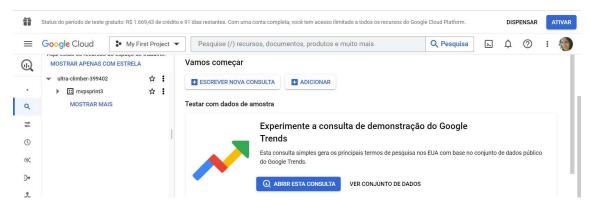
Buckets criados -



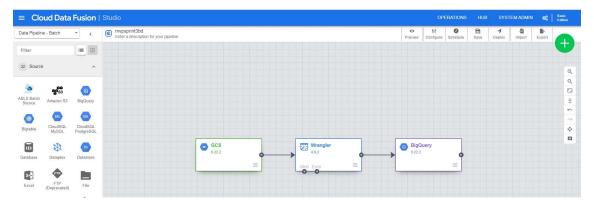
A imagem abaixo mostra o upload do arquivo "reatails_sales_dataset" para o bucket mvp-sprint3bd.



Finalizando a etapa de upload dos dados, segui para a criação do dataset mvpsprint3 no BigQuery, conforme imagem a seguir:

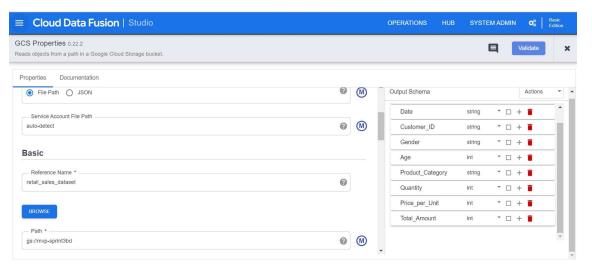


O próximo passo, através do Data Fusion Studio, foi criar as etapas do pipeline mvpsprint3bd: GCS, Wrangler e BigQuery



As imagens abaixo mostram as definições das propriedades das etapas do fluxo, GCS, Wrangler e BigQuery.

Primeiro, foi realizada a configuração do GCS para extrair os dados da fonte, que no caso foi o arquivo "reatails_sales_dataset" do bucket "mvp-sprint3bd".

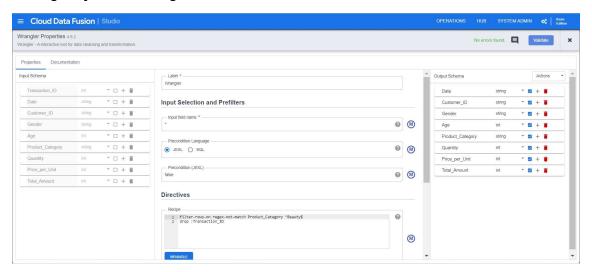


Em seguida, no Wrangler, foram realizadas as transformações dos dados:

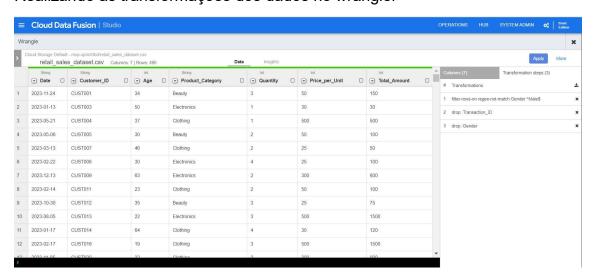
- 1. Exclusão do atributo "Transaction ID"
- 2. No atributo "Gender", foi feito o filtro "Male"
- 3. Exclusão do atributo "Gender"

Não foi necessária nenhuma ação de limpeza de dados, pois, como será apresentado no tópico de qualidade de dados, os dados não apresentavam erros, valores ausentes, nem duplicatas.

Configuração do wrangler -

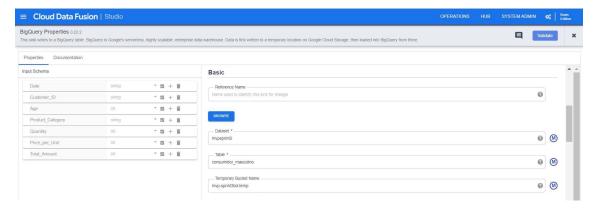


Realizando as transformações dos dados no wrangler -

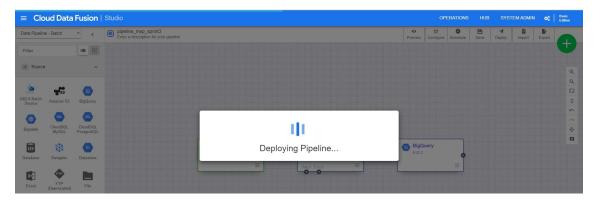


Após as transformações, a tabela ficou com 490 linhas e 7 atributos.

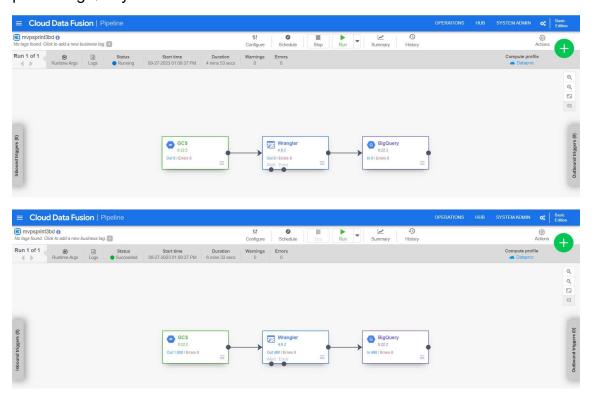
E por último, foi configurado os parâmetros necessários para carregamentos dos dados transformados no banco de dados BigQuery. A tabela carregada foi nomeada de "consumidor masculino", conforme imagem abaixo:



O passo seguinte foi fazer o "deploy" do fluxo, conforme imagem abaixo:



E, finalizado o deploy, foi acionado do RUN para realizar a carga dos dados para o BigQuery.





As etapas de Análise (qualidade dos dados e solução do problema) e Autoavaliação estão na Parte 2 do MVP, apresentado no notebook do Colab, que pode ser acessado no link:

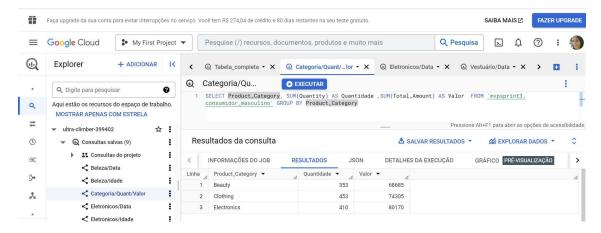
https://github.com/CarmemMarinho/poscienciasdedados/blob/main/MVP_Srint3 _EngenhariaDeDados_Parte2.ipynb

Para acessar os dados no Colab, utilizei o recurso disponível no BigQuery de "Analisar com notebook Python", como pode ser visto na imagem abaixo.

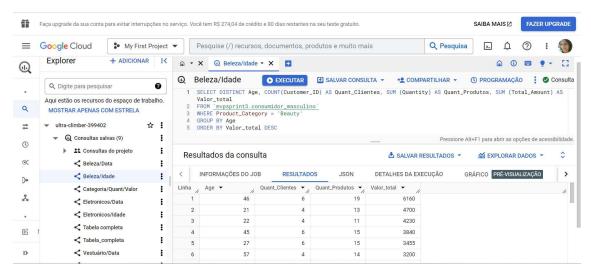


Entretanto, para aprendizado e complemento do trabalho, também fiz algumas análises no BigQuery utilizando SQL, conforme apresentado a seguir.

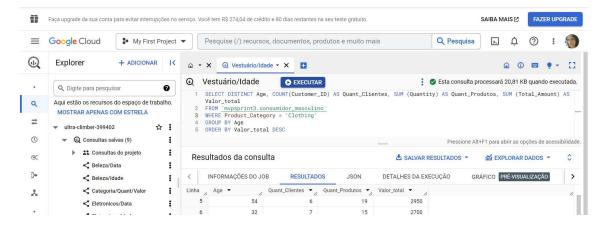
Consulta 1 – Quantidade total de produtos vendidos e faturamento total por categoria



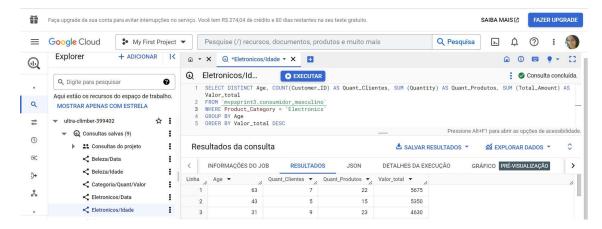
Consulta 2 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por idade, para a categoria "Beleza" (Beauty)



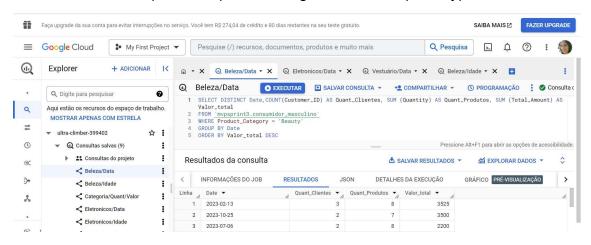
Consulta 3 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por idade, para a categoria "Vestuário" (Clothing)



Consulta 4 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por idade, para a categoria "Eletrônicos" (Electronics)



Consulta 5 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por data, para a categoria "Beleza" (Beauty)



Consulta 6 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por data, para a categoria "Vestuário" (Clothing)



Consulta 7 – Quantidade total de produtos vendidos, quantidade total de clientes e faturamento total por data, para a categoria "Eletrônicos" (Electronics)

